

Actividad de investigación: Machine Learning

Nombre del alumno: Fernando Emmanuel Perez
Lopez

Matrículas: 81660

Nombre del profesor(a): María Lizette López Muñoz

Asignatura: TÓPICOS DE BIG DATA

Carrera: Ingeniería en Software y Sistemas
Computacionales

Fecha de entrega: 14 de septiembre del 2026

1. Preparación de los Datos

Antes de entrenar un modelo, la información debe estar lista y limpia. Esta es la fase más importante del proceso.

- **Limpieza de datos:** Consiste en corregir errores, eliminar información irrelevante y dar un formato uniforme a los datos.
- **Valores faltantes y duplicados:** Los huecos vacíos se eliminan o se rellenan usando promedios. Los datos repetidos se borran para que el modelo no se confunda.
- **Valores atípicos:** Son datos anormales. Se deben tratar o eliminar porque distorsionan el aprendizaje.
- **Transformación y normalización:** Consiste en ajustar la escala de los números para que todas las variables sean comparables y ninguna domine a las demás.
- **Variables categóricas:** Como los algoritmos solo entienden números, el texto se debe convertir en valores numéricos.
- **Selección de variables:** Significa elegir solo la información que realmente es útil para hacer la predicción, descartando el resto.
- **Variables predictoras y objetivo:** Las variables predictoras son las pistas que le damos al modelo. La variable objetivo es lo que queremos adivinar.

2. Modelos

- **¿Qué es un modelo de Machine Learning?** Es un programa matemático que no sigue reglas fijas, sino que aprende a encontrar patrones analizando ejemplos.
- **Aprendizaje supervisado y no supervisado:** En el supervisado, le damos al modelo ejemplos que ya tienen la respuesta correcta. En el no supervisado, el modelo recibe datos sin respuestas y busca agruparlos por su cuenta.
- **Clasificación, regresión y clustering:** La clasificación adivina categorías. La regresión adivina números. El clustering agrupa cosas similares.
- **Regresión Lineal y Logística:** La Lineal traza una línea matemática para predecir números. La Logística calcula probabilidades para clasificar en categorías.
- **Árboles de Decisión y Random Forest:** El Árbol toma decisiones respondiendo preguntas de Sí o No. El Random Forest es un conjunto de muchos árboles de decisión trabajando juntos para ser más precisos.
- **KNN y K-Means:** KNN clasifica un dato nuevo basándose en sus vecinos más cercanos. K-Means agrupa datos por su similitud geométrica.
- **Datos de entrenamiento, validación y prueba:** Los datos se dividen en tres. Entrenamiento es para enseñar al modelo, validación para hacerle ajustes, y prueba para evaluar cómo reacciona ante datos que nunca ha visto.

- **Overfitting y underfitting:** El Overfitting o sobreajuste ocurre cuando el modelo memoriza los datos pero fracasa con información nueva. El Underfitting o subajuste pasa cuando el modelo es muy simple y no logra aprender.

3. Implementación y Evaluación

- **¿Qué significa evaluar un modelo?** Es medir matemáticamente qué tan buenas son las predicciones del modelo comparándolas con los resultados reales.
- **Métricas de clasificación:**
 - **Accuracy:** El porcentaje total de predicciones correctas.
 - **Precision:** De todos los casos que predijo como positivos, cuántos eran realmente positivos.
 - **Recall:** De todos los casos positivos reales, cuántos logró encontrar el modelo.
 - **F1-Score:** Es el equilibrio matemático entre Precision y Recall.
- **Métricas de regresión:**
 - **MAE:** Es el promedio del error en las unidades originales.
 - **MSE:** Es el promedio de los errores elevados al cuadrado.
 - **RMSE:** Es la raíz cuadrada del MSE, devolviendo el número a una escala fácil de entender.
 - **R²:** Un valor de 0 a 1 que indica qué tan bien explica el modelo la variación de los datos.
- **Matriz de confusión:** Es un concepto que cuenta en cuántos casos el modelo acertó y en cuáles se equivocó, dividiendo los resultados en verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos.